

**Московский государственный технический  
университет им. Н.Э. Баумана**

**Факультет «Радиотехнический»  
Кафедра «Системы обработки информации и управления»**

**Курс «Парадигмы и конструкции языков программирования»**

**Отчет по лабораторной работе №6  
«Парсинг текста с помощью языка Python»**

Выполнил:  
студент группы РТ5-31Б:  
Кузнецов С. А.

Подпись и дата:

Проверил:  
преподаватель кафедры ИУ5  
Гапанюк Ю. Е.

Подпись и дата:

Москва, 2024 г.

## Постановка задачи

Разработать программу, обрабатывающую экспортированный журнал Telegram-канала в формат, пригодный для обработки Telegram-ботом. В результате работы в рабочей директории создаётся txt-файл, в котором каждый пост разделён специальным символом (¶). Так как работа производится с конкретным Telegram-каналом, предусмотрен ряд подстановок текста.

## Текст программы

Файл «extracttext.py»:

```
import json

# Скрипт работает с экспортированными логами Telegram. В результате его
# работы
# генерируется файл sourcetext.txt с текстовым содержанием всех постов.

# Данный файл подогнан под обработку содержимого конкретного канала

path = "result.json" # Путь до файла

def process_export_log(path):
    with open(path, "r") as f:
        data = json.load(f) # Загружаем в память весь лог (плохо для больших
        # файлов?)

        data = data["messages"]
        parsed_data = (
            list()
        ) # Строки в Питоне неизменяемые, а мы хотим активно работать с форми-
        # руемой строкой
        droppable = False
```

```

departments = [
    "#ФН",
    "#ИУ",
    "#СГН",
    "#МТ",
    "#РК",
    "#РКТ",
    "#ФВ",
    "#Э",
    "#ИБМ",
    "СМ",
    "#Л",
    "#ЮР",
    "#РЛ",
    "#БМТ",
] # Список кафедр для произведения замены

for m in data: # Итерируемся по сообщениям
    if isinstance(m["text"], list): # Пустые сообщения игнорируются

        temp_pd = (
            list()

        ) # Может так случиться, что в сообщении встретится нежелательный
для корпуса контент

        droppable = False

        for mpart in m[
            "text"

```

]: # Поле "text" каждого сообщения содержит список частей сообщения

```
if isinstance(mpart, str) and not droppable:
```

```
    temp_pd.append(mpart)
```

```
    if mpart and mpart != " " and mpart[-1] != "\n":
```

```
        temp_pd.append(" ")
```

```
elif isinstance(mpart, dict) and not droppable:
```

```
    if (
```

```
        mpart["type"] != "link"
```

```
        and mpart["type"] != "mention"
```

```
        and mpart["type"] != "hashtag"
```

```
    ):
```

```
        temp_pd.append(mpart["text"])
```

```
        temp_pd.append(" ")
```

```
elif mpart["type"] == "hashtag":
```

```
    if (
```

```
        mpart["text"][-1].isnumeric()
```

```
        or mpart["text"].upper() in departments
```

```
    ):
```

```
        temp_pd.append("#ИИ5")
```

```
    else:
```

```
        temp_pd.append("#Роботник")
```

```
        temp_pd.append(" ")
```

```
elif mpart["type"] == "link":
```

```
    droppable = (
```

```
        True # Пропускаем сообщение с нежелательными элемен-
```

тами

```
    )
```

```

        else:
            continue

        if not droppable:
            temp_pd.append("¶") # Знаком параграфа будем означать конец со-
общения

            parsed_data.extend(temp_pd)
            parsed_data.append("\n\n")

        return "".join(parsed_data)

parsed_log = process_export_log(path)

with open("sourcetext.txt", "w") as f:
    print(parsed_log, file=f)

```

## Экранные формы с примерами выполнения про- граммы

Файл «main.py»:

```

PS C:\Users\User\Documents\BiquadraticEquations\PCPL> c:; cd 'c:\Users\User\Documents\BiquadraticEquations\PCPL'; & 'c:\Users\User\AppData\Local\Programs\Python\Python313\python.exe' 'c:\Users\User\vscode\extensions\ms-python.debugpy-2024.14.0-win32-x64\bundle\libs\debugpy\adapter\..\..\debugpy\launcher' '49347' '--' 'c:\Users\User\Documents\BiquadraticEquations\PCPL\extracttext.py'
PS C:\Users\User\Documents\BiquadraticEquations\PCPL>

```

```

sourcetext.txt
1  Эта формула для математиков.
2
3  #Роботник #ИИ5
4
5  ¶
6
7  Преподаватель, поясняя неуместность слишком частого использования указателей:
8  -Звездочки, это конечно хорошо. Но только если они на коньяке или на погонах. В коде же мы будем стараться обходиться без них.
9
10 #Роботник #ИИ5
11
12 ¶
13
14 "Понятно, что... нет, не понятно... интуитивно ясно"
15
16 #ИИ5 #Роботник
17
18 ¶
19
20 Базисы бывают хорошие, очень хорошие и прекрасные!
21
22 #Роботник #ИИ5
23

```